

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



1. VE 2. AZİ DİŞLERİNDE OLUŞAN EKTOPİK
ERUPSİYON ETKİLERİİNİN DERİN ÖĞRENME
YÖNTEMLERİ İLE İNCELENMESİ

21011003 – Doğukan BAŞ
20011007 – Bilal Müftüoğlu

BİLGİSAYAR PROJESİ

Danışman
Doç. Dr. Hamza Osman İLHAN

Haziran, 2024

TEŞEKKÜR

Dönem boyunca düzenli olarak bizimle toplantılar yapıp sorularımızı yanıtlayan, bizi yönlendiren sayın danışman hocamız Doç. Dr. Öğr. Üyesi Hamza Osman İlhan'a ve projemizde kullandığımız veri kümesini bizimle paylaşan Ordu Üniversitesi Diş Hekimliği Fakültesine teşekkürlerimizi sunarız.

Doğukan BAŞ
Bilal Müftüoğlu

İÇİNDEKİLER

KISALTMA LİSTESİ	v
ŞEKİL LİSTESİ	vi
TABLO LİSTESİ	viii
ÖZET	ix
ABSTRACT	xi
1 Giriş	1
2 Ön İnceleme	4
3 Fizibilite	8
3.1 Teknik Fizibilite	8
3.1.1 Yazılım Fizibilitesi	8
3.1.2 Donanım Fizibilitesi	8
3.2 Yasal Fizibilite	8
3.3 Ekonomik Fizibilite	8
3.4 İş Zaman Fizibilitesi	9
4 Sistem Analizi	10
4.1 Veri Toplama ve Etiketleme	10
4.1.1 Verilerin Genel İncelenmesi	10
4.1.2 Verilerin Histogram İle Analizi	11
4.1.3 Sistem Analizi	13
5 Sistem Tasarımı	14
5.1 Segmentasyon Modeli Tasarımı	14
5.2 Sınıflandırma Modeli Tasarımı	17
6 Uygulama	19
6.1 Adım Adım Uygulamanın Çalıştırılması	19

7 Deneysel Sonuçlar	23
7.1 Modellerin Başarısının Değerlendirilmesi	23
7.2 Uç Durumlarla Programın Test Edilmesi	26
8 Performans Analizi	28
8.1 Sınıflandırma Modellerinin Hata Matrislerinin Detaylı İncelenmesi	28
8.1.1 BeiT İkili Sınıflandırma Modelinin İncelenmesi	29
8.1.2 DeiT İkili Sınıflandırma Modelinin İncelenmesi	30
8.1.3 BeiT Hastalıklı Sınıflandırma Modelinin İncelenmesi	31
8.1.4 DeiT Hastalıklı Sınıflandırma Modelinin İncelenmesi	32
9 Sonuç	33
Referanslar	34
Özgeçmiş	35

KISALTMA LİSTESİ

R-CNN	Region-based Convolutional Neural Network
nn-U Net	no-new-Net
IoU	Intersection over Union
EE	Ektopik Erupsiyon
PFM	Birinci Kalıcı Azı Dişi
PSM	Üst Çenedeki İkinci Süt Azı Dişi
BERT	Bidirectional Encoder Representations From Transformers
DeiT	Data-efficient Image Transformer
BeiT	BERT Pre-Training of Image Transformers

ŞEKİL LİSTESİ

Şekil 1.1 Ektopik Erupsiyon Görüntüsü	2
Şekil 1.2 Tedavi Öncesi	3
Şekil 1.3 Tedavi Sonrası	3
Şekil 2.1 Ektopik Erupsiyonun Derin Öğrenme Yardımıyla Tespiti	4
Şekil 2.2 Model Analizi	5
Şekil 2.3 McNemar Testi	6
Şekil 2.4 Doktorlar ve Model Arasındaki Karşılaştırma	7
Şekil 3.1 Gantt Diyagramı	9
Şekil 4.1 Örnek Radyografi Görüntüsü	10
Şekil 4.2 Örnek Etiketler	11
Şekil 4.3 Sınıflandırılmış Etiketli Veri Dağılımı	11
Şekil 4.4 Polygonları Çizilmiş Json Veri Dağılımı	12
Şekil 4.5 Sistem Analizi	13
Şekil 5.1 Mask R-CNN Modeli Girdi Çıktı Tasarımı	14
Şekil 5.2 Mask R-CNN Maske Örnekleri	15
Şekil 5.3 Mask R-CNN Çalışma Prensibi [6]	16
Şekil 5.4 Sınıflandırma Modeli Girdi Çıktı Tasarımı	17
Şekil 5.5 Transformer Yapısı[7]	18
Şekil 6.1 Programın ilk çalıştırılması.	19
Şekil 6.2 Röntgen görüntüsünün programa yüklenmesi	20
Şekil 6.3 Görüntünün segmentasyon ve sınıflandırma sonucu	21
Şekil 6.4 Program Tarafından Kaydedilen Çıktı Görüntüleri	22
Şekil 7.1 5-Fold Segmentasyon Modelinin Hata Matrisi	23
Şekil 7.2 Sınıflandırma Veri Kümesinin Dağılımı	25
Şekil 7.3 BeiT İkili Sınıflandırma Modeli	25
Şekil 7.4 DeiT İkili Sınıflandırma Modeli	25
Şekil 7.5 BeiT Hastalıklı Sınıflandırma Modeli	25
Şekil 7.6 DeiT Hastalıklı Sınıflandırma Modeli	25
Şekil 7.7 Örnek Çıktı 1	26
Şekil 7.8 Örnek Çıktı 2	27
Şekil 7.9 Örnek Çıktı 3	27

Şekil 8.1	55 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi	29
Şekil 8.2	65 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi	29
Şekil 8.3	75 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi	29
Şekil 8.4	85 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi	29
Şekil 8.5	55 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi	30
Şekil 8.6	65 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi	30
Şekil 8.7	75 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi	30
Şekil 8.8	85 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi	30
Şekil 8.9	55 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . . .	31
Şekil 8.10	65 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . . .	31
Şekil 8.11	75 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . . .	31
Şekil 8.12	85 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . . .	31
Şekil 8.13	55 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . .	32
Şekil 8.14	65 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . .	32
Şekil 8.15	75 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . .	32
Şekil 8.16	85 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi . .	32

TABLO LİSTESİ

Tablo 7.1 Sınıflandırma modellerinin performans karşılaştırması 24

ÖZET

1. Ve 2. AZİ DİŞLERİNDE OLUŞAN EKTOPİK ERUPSİYON ETKİLERİİN DERİN ÖĞRENME YÖNTEMLERİ İLE İNCELENMESİ

Doğuakan BAŞ

Bilal Müftüoğlu

Bilgisayar Mühendisliği Bölümü

Bilgisayar Projesi

Danışman: Doç. Dr. Hamza Osman İLHAN

Ektopik Erupsiyon dişlerin normal diş pozisyonundan saparak ağızda anormal bir pozisyonda çıkmasıdır. Bu durum genellikle üst çenenin azı dişlerinde gözükür. Bu dişler 55 ve 65 numaralı süt dişleri ile 16 ve 26 numaralı kalıcı azı dişleridir. Alt çenede ise 75 ve 85 numaralı süt dişleri ile 36 ve 46 numaralı kalıcı azı dişlerinde az da olsa ektopik erupsiyon görülmektedir. Çocuklarda süt azı dişinin altından çıkan kalıcı azı dişinin ektopik erupsiyona neden olup olmadığından erken aşamada tespiti uygulanacak tedavi açısından önemlidir. Bu projede derin öğrenme yöntemleri kullanılarak bu dişlerde ektopik erupsiyon görülüp görülmediğini şiddetitle beraber tespit edip kullanıcının bilgisine sunan bir uygulama geliştirilmiştir. Uygulamanın klinik ortamda hekimler tarafından kullanılması planlanmıştır. İlk olarak Mask R-CNN modeli kullanılarak radyografi görüntüünde bulunan azı dişleri kırılmıştır. Daha sonra tespit edilmiş ikili gruplar halinde (azı dişi ve yanındaki süt dişi) kırılan bu azı dişleri DeiT ve BeiT kullanılarak geliştirilen ikili sınıflandırma modeline verilmiştir. İkili sınıflandırma modeli ile verilen diş ikilisinde ektopik erupsiyon olup olmadığı tespit edilmiştir. Modelin çıktısı "Normal" ise kullanıcıya sonuç ve güven yüzdesi değeri sunulmuştur eğer modelin çıktısı "Hasta" ise segmentasyon modelinin çıktısı başka bir sınıflandırma modeline verilmiştir. Bu sınıflandırma modeli de DeiT ve BeiT kullanılarak yazılmıştır ve verilen görüntüdeki dişi "Hafif Seviyede Hasta", "Orta Seviyede Hasta" ve "Şiddetli Seviyede Hasta" olmak üzere üç sınıfta sınıflandırıp grafik arayüz aracılığıyla kullanıcıya sınıflandırma modeli çıktısı ve güven yüzdesi değeri

sunulmuştur.

Anahtar Kelimeler: Ektopik Erupsiyon, Mask R-CNN, DeiT, BeiT, Sınıflandırma, Segmentasyon

ABSTRACT

Detection of Ectopic Eruption Effects on 1st and 2nd Molar Teeth Using Deep Learning Methods

Doğuakan BAŞ

Bilal Müftüoğlu

Department of Computer Engineering

Computer Project

Advisor: Assoc. Prof. Dr. Hamza Osman İLHAN

Ectopic eruption is the eruption of teeth in an abnormal position in the mouth, deviating from the normal tooth position. This condition is usually seen in the molars of the maxilla. These teeth are deciduous teeth numbered 55 and 65 and permanent molars numbered 16 and 26. In the mandibular, ectopic eruption is rarely seen in deciduous teeth numbered 75 and 85 and permanent molars numbered 36 and 46. In children, early detection of whether the permanent molar coming out from under the deciduous molar causes ectopic eruption is important for the treatment to be applied. In this project, an application has been developed using deep learning methods to detect whether ectopic eruption is seen in these teeth together with its severity and present it to the user's information. The application is planned to be used by physicians in a clinical environment. First, the molars in the radiography image were cropped using the Mask R-CNN model. Then, these molars, which were detected and cropped in binary groups (molar and adjacent deciduous tooth), were given to the binary classification model developed using DeiT and BeiT. The binary classification model was used to determine whether the given pair of teeth had ectopic eruption. If the output of the model is "Normal", the user is presented with the result and confidence percentage value. If the output of the model is "Diseased", the output of the segmentation model is given to another classification model. This classification model is also written using DeiT and BeiT and classifies the tooth in the given image into three classes as "Mild Diseased", "Moderate Diseased" and "Severe Diseased" and presents the classification model output and confidence percentage value to the user.

through a graphical interface.

Keywords: Ectopic Eruption, Mask R-CNN, DeiT, BeiT, Classification, Segmentation

1

Giris

Ektopik erupsiyon bir dişin normalde çıkışının gerektiği yerden farklı bir yerde çıkışmasıdır. Bu durumun tespiti çocuklarda gösterilecek tedavi açısından büyük önem arz eder. Dolayısıyla erken teşhis oldukça önemlidir.

Seçil Çalışkan ve arkadaşları, birinci kalıcı azı dişinin(PFM) anormal şekilde ne sıklıkla erupsiyona uğradığını, konumlandırma açısını ve ağızin önüne doğru ne kadar kaydığını (mezialisasyon oranı) ve bu faktörlerin üst çenedeki ikinci süt azı dişi (PSM) kökünün aşınmasına nasıl ilişkili olduğunu incelemiştir [1]. Araştırmacılar, 6-10 yaşları arasındaki 11.924 çocuğun panoramik röntgenlerini kullanarak retrospektif bir analiz gerçekleştirdiler. Ektopik erupsiyonu kendiliğinden düzeltmiş veya etkilenmiş olarak sınıflandırdılar ve bu grupları birinci kalıcı azı dişinin konumlandırma açısı, mezialisasyon oranı ve yan ikinci süt azı dişi kök rezorpsiyon derecesi açısından karşılaştırdılar. Araştırmada elde edilen bazı önemli sonuçlar şunlardır:

- Ektopik erupsiyon vakaları %0,83 oranında görüldü ve erkeklerde daha yaygın olarak gözlendi.
- Ektopik erupsiyon vakalarının çoğu etkilenmiş sınıfındaki birinci kalıcı azı dişleri idi.
- Erupsiyona uğramış birinci kalıcı azı dişleri daha çok aşağıya ve yanak yönüne doğru konumlanma eğilimindeydi.

Sonuç olarak erken teşhis ve süreç yönetiminin önemi anlaşılmıştır. Erupsiyonun gerçekleştiği biçim (pattern) ve açısı tartışımlı olsa da anahtar bir klinik faktör olarak görülmektedir.

Inês Leandro ve arkadaşları dünya çapındaki arkeolojik popülasyonlarda tanımlanan ilk ektopik erupsiyon vakasını incelemiştir. İnceledikleri iskeletin, 14. ile 16. yüzyıllar arasında yaşadığı tahmin edilmektedir [2]. İskeletin kötü korunmuş olmasına rağmen, analizler, muhtemelen 29 yaşından büyük bir kadın olduğunu göstermektedir. Üçüncü alt çene azı dişinde büyük bir diş göçünün meydana geldiği açık bir şekilde belli olmaktadır. Dişlerin normal pozisyonlarına gelmek için uzak yerlerden çıktıığı birçok vaka olmuştur. Ancak bu kadar uzak bir noktada çıktıığı vaka çok nadirdir. Bu ektopik erupsiyon vakasına ait görüntü Şekil 1.1'de görülmektedir.



Şekil 1.1 Ektopik Erupsiyon Görüntüsü

Jui-Hsien Yang ve arkadaşlarının incelediği bu vakada, 9 yaşında bir erkek hasta, sağ üst çenesindeki yan kesici dişinin çıkmamış olduğu şikayetyle bir ortodontiste başvurmuştur [3]. Diş hekimleri, hastanın hafif kesici diş kalabılığı ve çıkmamış bir dişi (12 numaralı diş) olduğuna karar vermiştir. Bu durumda, hastanın ebeveynlerine iki tedavi yöntemi sunulmuştur: Diş tamamen ağızdan çekmek veya dişi diş dizisine geri getirmek. Aile, çocuğun daha sağlıklı bir diş yapısına sahip olması için dişi diş dizisine geri getirmeyi tercih etmiştir. Bir yıl süren tedavinin ardından, diş 12 diş kemerine hizalanmış ve kesici kalabılığı sorun olmaktan çıkmıştır. Vakanın tedavi öncesi ve tedavi sonrası görüntüleri Şekil 1.2 ve Şekil 1.3'te görülmektedir.



Şekil 1.2 Tedavi Öncesi

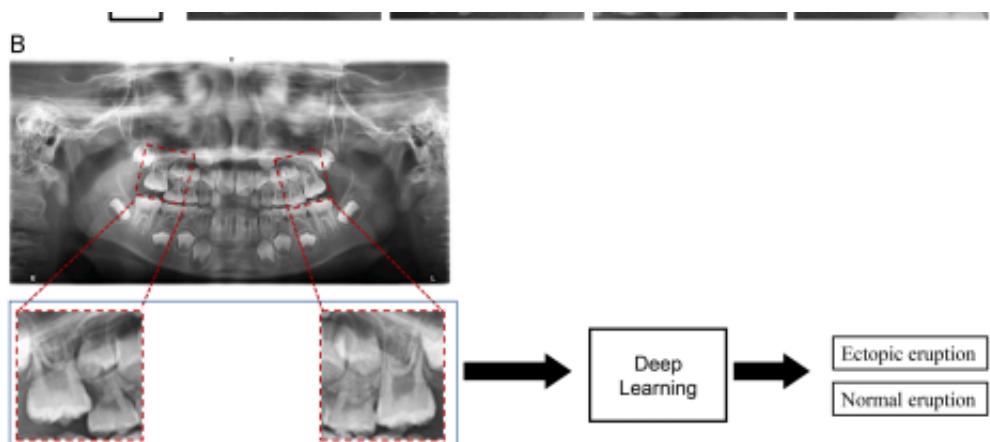


Şekil 1.3 Tedavi Sonrası

Bu projede kesici dişler ile veya ektopik erupsiyon vakalarının tedavisi ile ilgilenilmemektedir ancak yine de yaşanan bu vaka ektopik erupsiyonun erken teşhisinin ne kadar önemli olduğunu göstermek için iyi bir örnektir. Bu da bu projenin önemini vurgulamaktadır.

2 Ön İnceleme

Derin öğrenme ile radyografi görüntülerine dayanarak ektopik erupsiyonun tespitiyle ilgili çalışma yapan Jialing Liu ve arkadaşları radyograflarda erupsyon anomalilerini tespit etmenin deneyime bağlı olmasından, zamanında müdahalelere izin vermek için otomatik modeller geliştirmenin faydasını fark etmiş ve bu alanda çalışma yürütmüştür [4]. Derin öğrenmeye dayalı otomatik tarama sistemleri, üst çenedeki kalıcı birinci aza dişlerinin ektopik erupsyonunu nispeten yüksek başarıyla tespit etmede yararlıdır ve umut vadeder. Ancak olası yanlış negatif teşhis etkisini en aza indirmek için düzenli takipler gereklidir. Ektopik erupsyon yaşayan hastalar genellikle gecikmiş diş çıkma şikayetiyle diş hekimine başvururlar, bu nedenle ilk muayene genellikle ortalama 7 yaşında gerçekleşir. Ektopik erupsyonun tespitinin aşamaları Şekil 2.1'de görülmektedir.



Şekil 2.1 Ektopik Erupsyonun Derin Öğrenme Yardımıyla Tespiti

Derin öğrenme algoritması başlamadan önce, orijinal panoramik görüntülerden girdi bölgeleri iki adımlı bir prosedürde kırıldı. İlk olarak, bilgisayar orijinal panoramik görüntüde sol ve sağ PFM (kalıcı birinci ağız dışı) yakınında yaklaşık olarak iki sınırlayıcı kutu oluşturdu. İkinci olarak, dış hekimleri sınırlayıcı kutuların boyutunu ve konumunu manuel olarak ayarlayarak her şeyin doğru olduğundan emin oldu. Maksiller sol ve sağ PFM'ler ile yanındaki PSM'ler (kalıcı ikinci ağız dışları) bölgeleri orijinal görüntülerden çıkarıldı, daha sonra tanıma için 400×400 piksele yeniden boyutlandırıldı. Maksiller sol ve sağ bölgeler sırasıyla değerlendirildi. Derin öğrenmeye dayalı görüntü sınıflandırmasında, bir görüntünün özellikleri kademeli evrişim katmanlarıyla çıkarılır. Bu çalışma için 4-9 yaş aralığında geniş bir yaşı aralığı seçildi, böylece mümkün olan kadar çok EE belirtisi kapsamış oldu. Sonunda, çalışmaya 1580 görüntü dahil edildi, bunların 1480 görüntüsü (2960 bölge) eğitim setine ve 100 görüntüsü (200 bölge) test setine ayrıldı. Sonunda, Şekil 2.2'de görüldüğü üzere füzyon modeli EE'yi 0.8824 F1-Skoru ile tespit edebildi. Ancak, yanlış pozitif olasılığı %0.1 ve yanlış negatif olasılığı da %0.1'dir.

Quadrant	Operator	SEN	SPEC	PPV	NPV	F1-Score
Maxillary left	Fusion Model	0.9000	0.8600	0.8654	0.8958	0.8824
	Expert 1	0.8400	0.8800	0.8750	0.8462	0.8571
	Expert 2	0.8600	0.8200	0.8269	0.8542	0.8431
	Expert 3	0.8800	0.8600	0.8627	0.8776	0.8713
Maxillary right	Fusion Model	0.8800	0.8600	0.8627	0.8776	0.8713
	Expert 1	0.8600	0.8800	0.8776	0.8627	0.8687
	Expert 2	0.9200	0.8400	0.8519	0.9130	0.8846
	Expert 3	0.8200	0.8800	0.8723	0.8302	0.8454
Overall	Fusion Model	0.8900	0.8600	0.8641	0.8866	0.8768
	Expert 1	0.8500	0.8800	0.8763	0.8544	0.8629
	Expert 2	0.8900	0.8300	0.8396	0.8830	0.8641
	Expert 3	0.8500	0.8700	0.8673	0.8529	0.8586

Şekil 2.2 Model Analizi

Haihua Zhu ve arkadaşlarının yapmış olduğu çalışmada ektopik erupsyonun erken dönemde teşhisinin zor olması nedeniyle teşhis aşamasında yapay zeka kullanımının öneminden bahsedilmektedir [5]. Çalışmada eğitilen model için yaşıları 5 ile 13 arasında değişen 8254 çocuktan 285 panoramik radyografi görüntüsü seçilmiş ve bu radyograflerden 438 bölge elde edilmiş. Nnu-net için kullanılmadan önce hepsi aynı formata, aynı çözünürlüğe ve gri tonlamaya dönüştürülmüş. Birinci kalıcı ağız dişinin 347 ektopik sürmesini içeren 220 panoramik görüntü, eğitim seti için rastgele seçilmiş ve kalanı test için ayrılmış. Çalışmada, anlamsal bölümlemedeki mükemmel performansıyla bilinen U-Net modelinin bir çeşidi olan nnU-Net mimarisi kullanılmış. Model, ağırlıklarını optimize etmek için veri kümesi özelliklerine göre otomatik olarak yapılandırılmış. Modeli eğitmek için kullanılan görüntülere pediyatrik diş hekimleri tarafından manuel segmentasyon uygulanmış ancak diş hekimleri arasında manuel segmentasyon farklılıklarını nedeniyle, anotasyonların en büyük kesimleri alınmıştır. Giriş panoramik görüntüsünün her pikseline bir sınıf etiketi atanmış. Ağ, görüntülerin ve karşılık gelen segmentasyon haritalarının küçük gruplar halinde girilmesiyle eğitilir. NnU-Net modeli, önceden eğitilmiş bir U-Net mimarisi kullandı ve dinamik öğrenme oranıyla 100 yinelemelik eğitime tabi tutulmuş. Başlangıçta öğrenme oranı 0,01 olarak belirlenmiş ve eğitim süreci boyunca giderek azaltılmış. NnU-net modelinin performansını analiz etmek için dört parametre incelenmiştir: IoU, precision, accuracy ve F1-Skoru. Farklı diş hekimlerinin güvenilirliğini değerlendirmek için ICC'ler, nnU-net modelinin diş hekimleri ile karşılaştırmasını değerlendirmek için ise McNemar ki-kare testi uygulanmıştır. McNemar testinin sonuçları Şekil 2.3'te görülmektedir. Test sonuçları nnU-net modelinin anlamlı ve doktorlara göre üstün olduğunu göstermiştir.

McNemar's test

	Model and Dentist 1	Model and Dentist 2	Model and Dentist 3
χ^2	16.056	15.059	19.048
<i>p</i>	<.001	<.001	<.001

Şekil 2.3 McNemar Testi

Model, 0,834'lük Birleşim Üzerindeki Kesişme (IoU) ile etkileyici performans ölçümüleri elde etti; bu, segmentasyon sonuçları ile açıklama aralığı arasında iyi bir tutarlılık olduğunu gösteriyor. 0,845'lik hassasiyet, modelin birinci kalıcı azı dişinin (EMM) Ektopik Erupsiyonunu doğru bir şekilde tahmin etme yeteneğini gösterir. 0,902'lük F1 puanı, modelin EMM'leri tespit etmedeki üstün performansını daha da öne çıkarmaktır. Son olarak, 0,990'luk yüksek doğruluk, modelin EMM'leri doğru şekilde tanımlamadaki güçlü teşhis yeteneğini gösterir. Şekil 2.4 görüldüğü üzere tasarlanan sistem IoU, precision, F1-Skoru, accuracy gibi metriklerde 3 hekimden de daha iyi bir performans sergilemiştir.

	IoU	Precision	F1-score	Accuracy
System	0.834	0.845	0.902	0.990
Dentist 1	0.515	0.583	0.720	0.825
Dentist 2	0.590	0.562	0.737	0.833
Dentist 3	0.484	0.471	0.640	0.775
Mean dentists	0.530	0.539	0.699	0.811

Şekil 2.4 Doktorlar ve Model Arasındaki Karşılaştırma

3

Fizibilite

3.1 Teknik Fizibilite

3.1.1 Yazılım Fizibilitesi

Segmentasyon, sınıflandırma ve kullanıcıya sunulacak olan grafik kullanıcı arayüzü için Python programlama dili kullanılmaktadır.

3.1.2 Donanım Fizibilitesi

Bu projenin donanım gereksinimi geliştirme aşamalarında kullanılacak bir bilgisayardır. Modellerin eğitimi bulut sistem üzerinde gerçekleştirildiği için geliştirme yapılacak bilgisayarın çok güçlü olmasına gerek yoktur. 8GB Ram ve 100 GB disk alanına sahip bir bilgisayar ile geliştirme yapılmaktadır.

3.2 Yasal Fizibilite

Projede kullanılan yazılımlar açık kaynaklı olduğundan herhangi bir yasal yükümlülük bulunmamaktadır.

3.3 Ekonomik Fizibilite

Proje sürecinde modellerin eğitiminde kullanılan "Google Collab" için 165 TL ödeme gerçekleştirılmıştır.

3.4 İş Zaman Fizibilitesi

Proje için planlanan iş zaman fizibilitesine ait gantt diyagram Şekil 3.1'de görülmektedir.



Şekil 3.1 Gantt Diyagramı

4

Sistem Analizi

4.1 Veri Toplama ve Etiketleme

4.1.1 Verilerin Genel İncelenmesi

Çalışma kapsamında kullanılacak veri kümesi Ordu Üniversitesi Diş Hekimliği Fakültesi tarafından sağlanmıştır. Veri kümesinde 876 adet panoramik radyografi görüntüsü vardır. Örnek bir radyografi görüntüsü Şekil 4.1'de görülmektedir. Şekil 4.2'de görüleceği üzere veri kümesindeki radyografi görüntüleri Ordu Üniversitesi Diş Hekimliği Fakültesi hekimlerince etiketlenmiştir. Bu projedeki modellerin eğitimi ve validasyonu ilgili veri kümesindeki 876 adet görüntü üzerinden gerçekleştirilecektir.



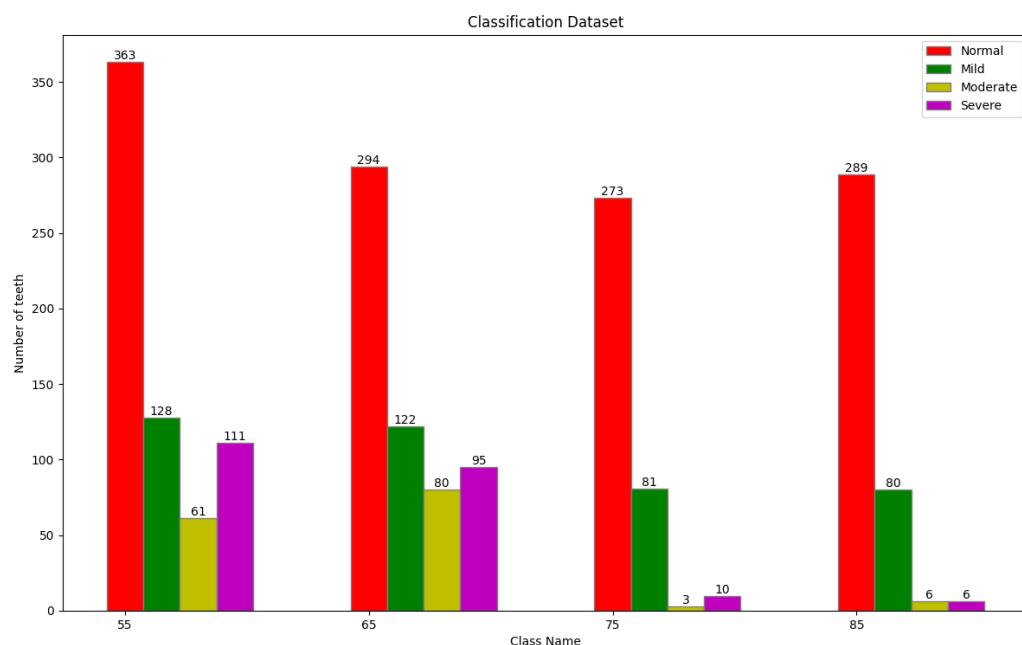
Şekil 4.1 Örnek Radyografi Görüntüsü

Ad soyad		55	65	75	85 Cinsiyet
001_123615006MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
002_1001141814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	KIZ
003_1002155934ÖMENASHSU1012180515541ÖMENASHSU1012180515541.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
004_1002155936ÖMENASHSU1012180515541ÖMENASHSU1012180515541.bmp	NORMAL	NORMAL	NORMAL	NORMAL	KIZ
005_100114181814MERWAATP0317181609ÖMENASH1900.bmp	ORTA	ORTA	NORMAL	NORMAL	ERKEK
006_1005155936EMRAHILMIKL1012180515541EMRAHILMIKL1012180515541.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
007_100615593721EMRAHOSUMOGLU1012180515541EMRAHOSUMOGLU1012180515541.bmp	ETİKETLENMEDİ	HAFIF	NORMAL	HAFIF	KIZ
008_100114181814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
009_100114181814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	KIZ
010_1001150526CATERKERIMSAHNR5601105250CATERKERIMSAHNR5601105250.bmp	HAFIF	NORMAL	HAFIF	NORMAL	ERKEK
011_100114181814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
012_100114181814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
013_1001131001MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	ŞİDDETLİ	ETİKETLENMEDİ	ETİKETLENMEDİ	ERKEK
014_1001172028basenTalha102722330728basenTalha102722330728.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK
015_100114181814MERWAATP0317181609ÖMENASH1900.bmp	NORMAL	NORMAL	NORMAL	NORMAL	ERKEK

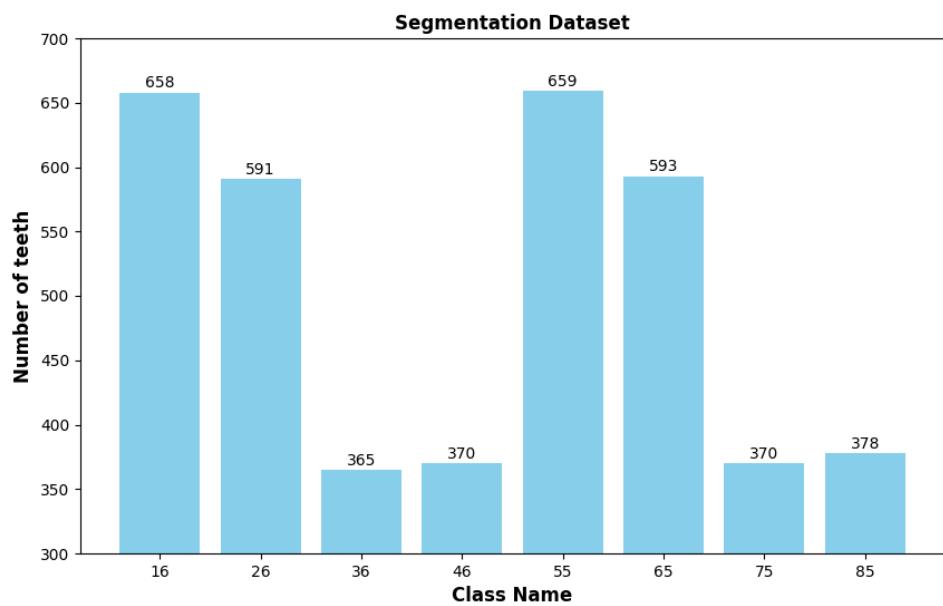
Şekil 4.2 Örnek Etiketler

4.1.2 Verilerin Histogram İle Analizi

Çalışmada kullanılacak verilerin sınıf dağılımları aşağıdaki histogramlarda gösterilmiştir. Şekil 4.3 ve Şekil 4.4'te görüleceği üzere şiddetli ektopik erupsiyon görülen dişler genel olarak 55 ve 65 numaralı dişlerdir. Bu dişler üst çenede bulunan azı dişleridir. Buradan yola çıkarak ektopik erupsiyon vakalarının alt çeneye oranla üst çenede daha sık görüldüğü yorumu yapılabilmektedir.



Şekil 4.3 Sınıflandırılmış Etiketli Veri Dağılımı



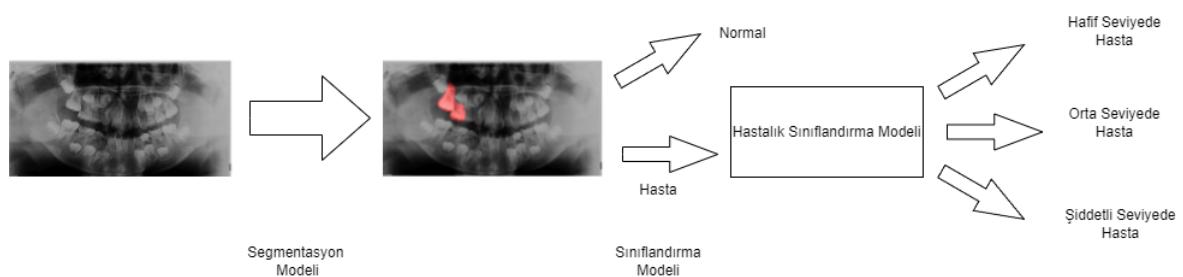
Şekil 4.4 Polygonları Çizilmiş Json Veri Dağılımı

4.1.3 Sistem Analizi

Geliştireceğimiz sistem girdi olarak bir radyografi görüntüsü alıp çıktı olarak normal, hafif seviyede hasta, orta seviyede hasta ve şiddetli seviyede hasta olmak üzere 4 sınıftan oluşan sınıflandırmanın sonucunu vermelidir.

Burada yapılacak ilk işlem segmentasyon modeli eğitmektir. Bu segmentasyon modeli ile hedeflenen şey verilen bir radyografi görüntüsünden sadece üst çenede bulunan 55, 65 numaralı süt azı dişleri ile 16, 26 numaralı kalıcı azı dişlerinin alt çenede ise 75, 85 numaralı süt azı dişleri ile 36, 46 numaralı kalıcı azı dişlerinin polygonlarının çizilmesi yani kırılmasıdır.

Segmentasyon ile 1. ve 2. azı dişleri tespit edildikten sonra bu görüntüler üzerinde sınıflandırma modeli çalıştırılacak, bu hastanın hangi dişlerinde ektopik erupsiyon olduğu tespit edilecek ve bunların normal, hafif seviyede yamuk, orta seviyede yamuk ve şiddetli seviyede yamuk olarak sınıflandırması yapılacaktır. Bu akışı ifade eden diyagram Şekil 4.5'te görülmektedir.



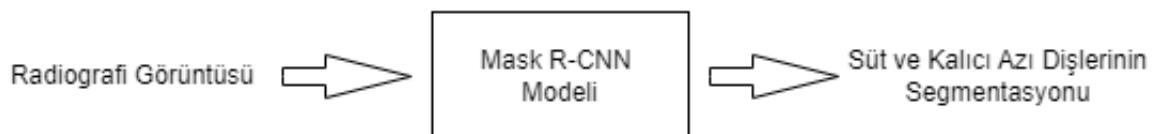
Şekil 4.5 Sistem Analizi

5

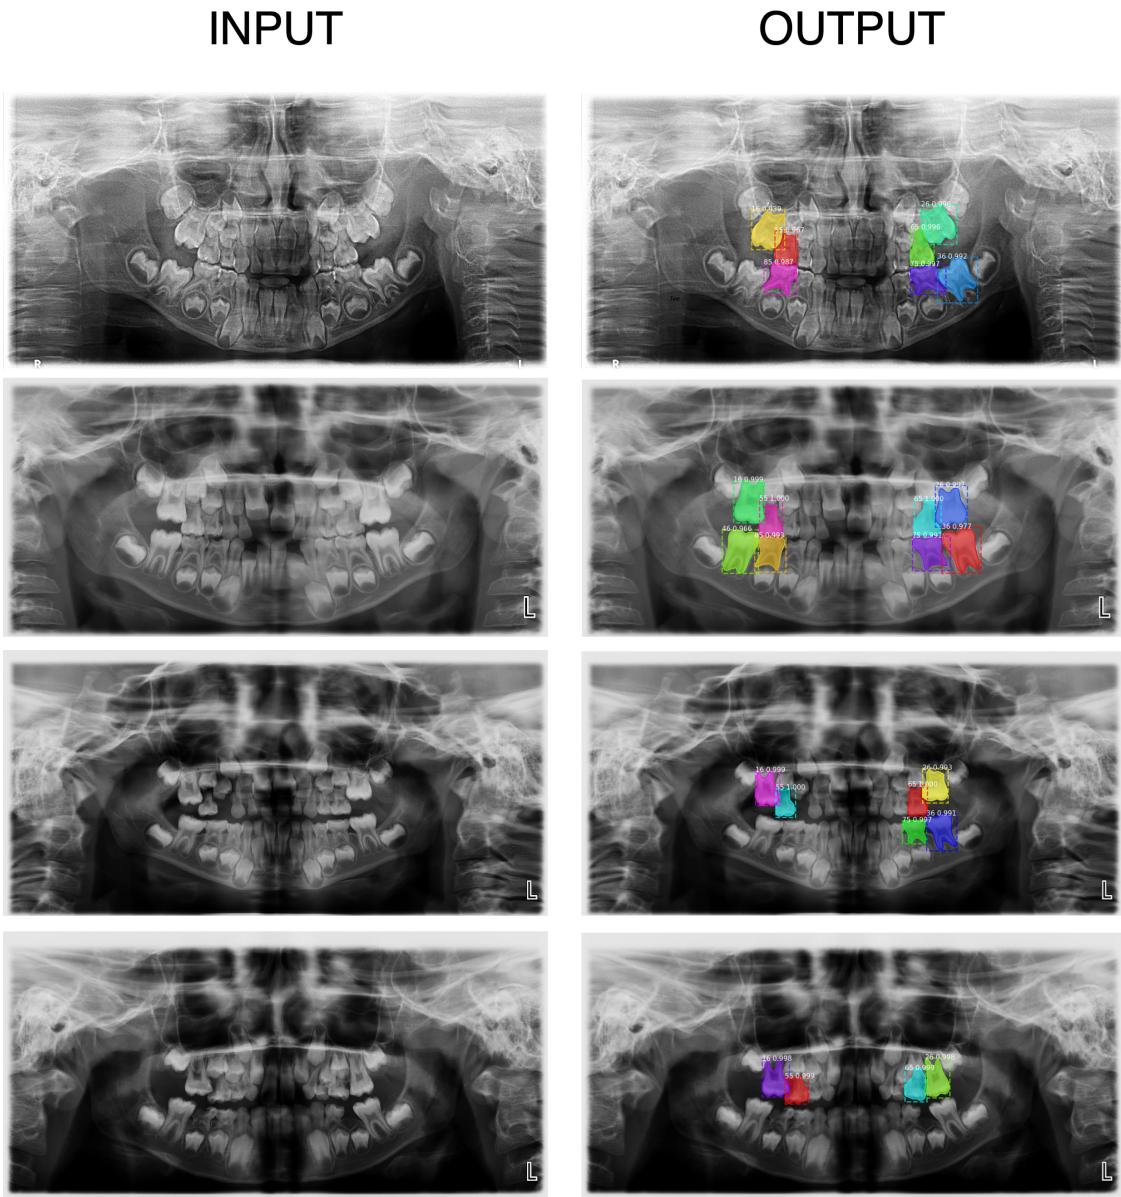
Sistem Tasarımı

5.1 Segmentasyon Modeli Tasarımı

Sistem analizi kısmında bahsedildiği üzere radyografi görüntüsünden ilgili azı dişlerinin elde edilmesi için bir birey segmentasyonu (Instance Segmentation) algoritmasına ihtiyaç vardır. Dolayısıyla bu aşamada dişlerin maskelenmesi için bir birey segmentasyonu algoritması olan Mask R-CNN kullanılacaktır. Mask R-CNN modeli için örnek girdi çıktı diyagramı Şekil 5.1'de girdi çıktılarına ait örnekler Şekil 5.2'de verilmiştir

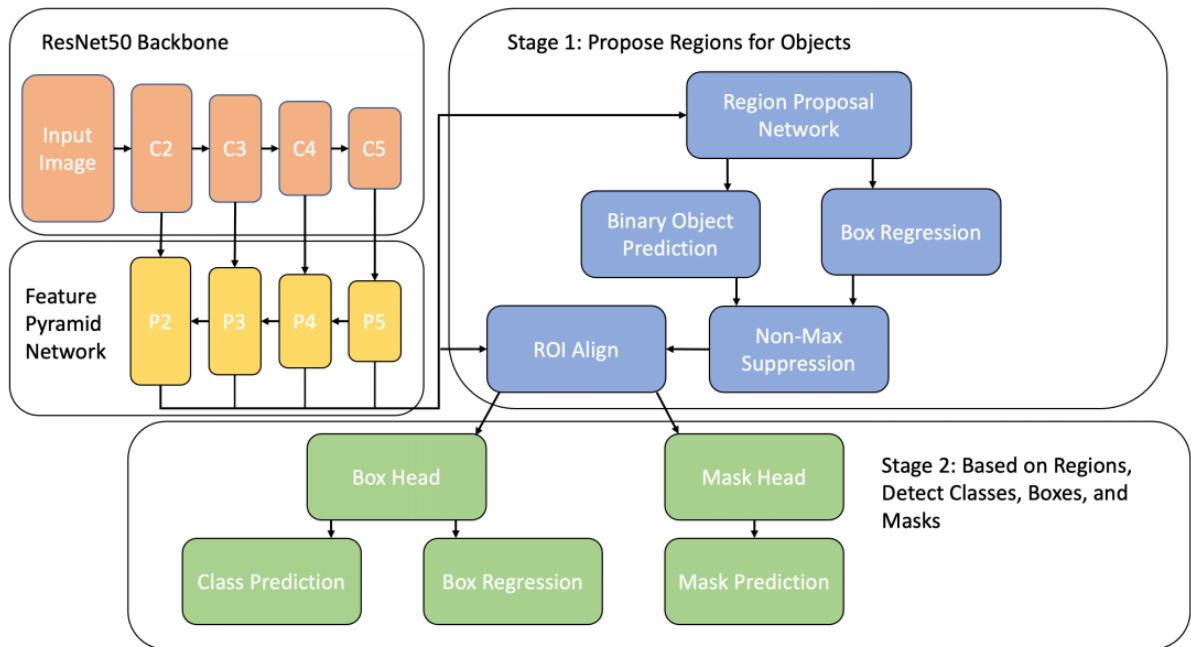


Şekil 5.1 Mask R-CNN Modeli Girdi Çıktı Tasarımı



Şekil 5.2 Mask R-CNN Maske Örnekleri

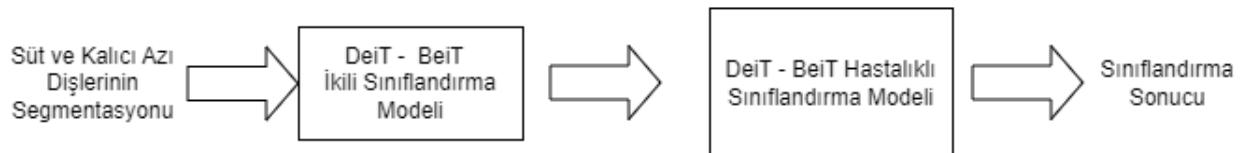
Bölge tabanlı evrişimsel sinir ağı olan Mask Region-based Convolutional Neural Network (Mask R-CNN) Faster R-CNN modeli temelinde geliştirilmiş derin sinir ağı modelidir. Mask R-CNN'nin Faster R-CNN'den en büyük farkı tahmin edilen nesne yüzeyinin renklendirilerek maskeleme işlemi yapılmasıdır. Modelin çalışma prensibi Şekil 5.3'de verilmiştir. Mask R-CNN modeli 2 aşamalı bir prosedürden oluşmaktadır. İlk prosedür olan Bölge Teklif Ağı (Region Proposal Network-RPN) aşamasında bir nesneyi içermeye olasılığı yüksek olan alanları bulur. İkinci aşamada ise önerileri sınıflandırır ve ROI Hizalama (ROI Align) katmanını kullanarak sınırlayıcı kutular ve piksel düzeyinde her nesne için maskeler oluşturur.



Şekil 5.3 Mask R-CNN Çalışma Prensibi [6]

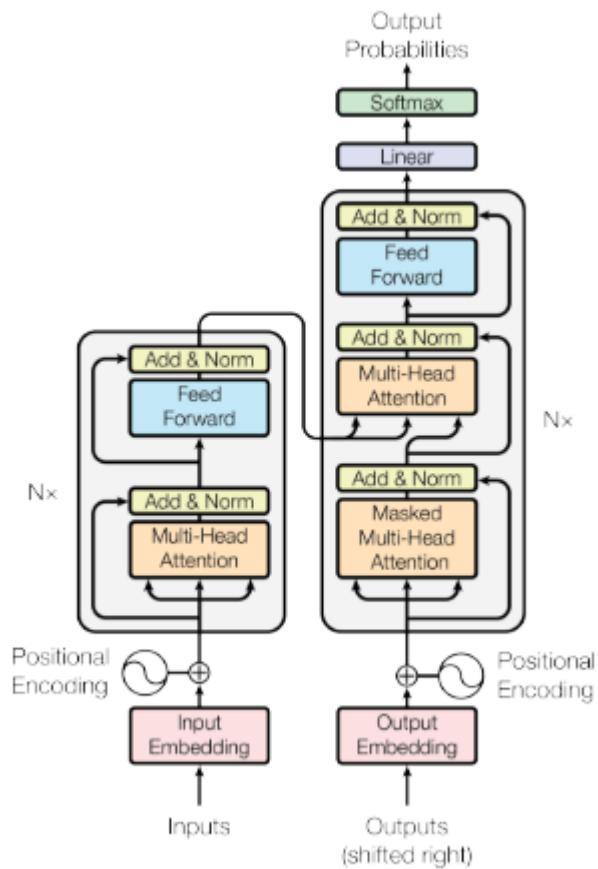
5.2 Sınıflandırma Modeli Tasarımı

Segmentasyon ile dişleri başarılı bir şekilde elde ettikten sonra bunları tek tek sınıflandırmak gerekmektedir. Sınıflandırmak için ise Data Efficient Image Transformer (DeiT) veya BERT Pre-Training of Image Transformers (BeiT) algoritmaları kullanılacaktır. Modellerin kullanım akışı Şekil 5.4'te verilmiştir.



Şekil 5.4 Sınıflandırma Modeli Girdi Çıktı Tasarımı

Birer transformer modeli olan DeiT ve BeiT modellerinin ikisi de görüntüyü belli sayıda parçalara (patch) bölüp dizi şekline getirir. Transformer modellerinin çalışma prensibine ait görüntü Şekil 5.5'te verilmiştir. Her bir patch için doğrusal dönüşüm yapılarak bir embedding oluşturur ve patchler vektör uzayda temsil edilirler. DeiT modeli veri verimliliğini artırmak için distilasyon ve augmentasyon tekniklerini kullanır bu sayede daha küçük veri kümelerinde de başarılı sonuçlar verebilmektedir. BeiT modelinde ise bazı parçalar maskelenir ve modelin bu kısımları tahmin etmesi beklenir. Böylece model görüntülerin iki yönlü temsiliyetlerini öğrenebilmektedir.



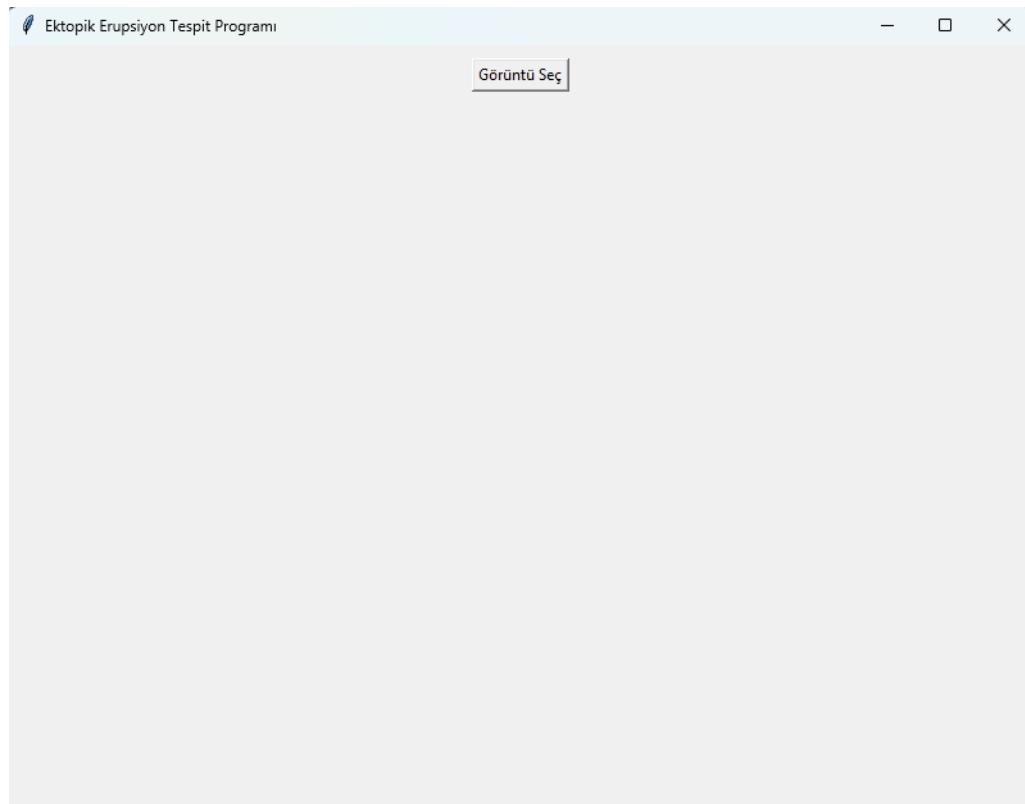
Şekil 5.5 Transformer Yapısı[7]

6

Uygulama

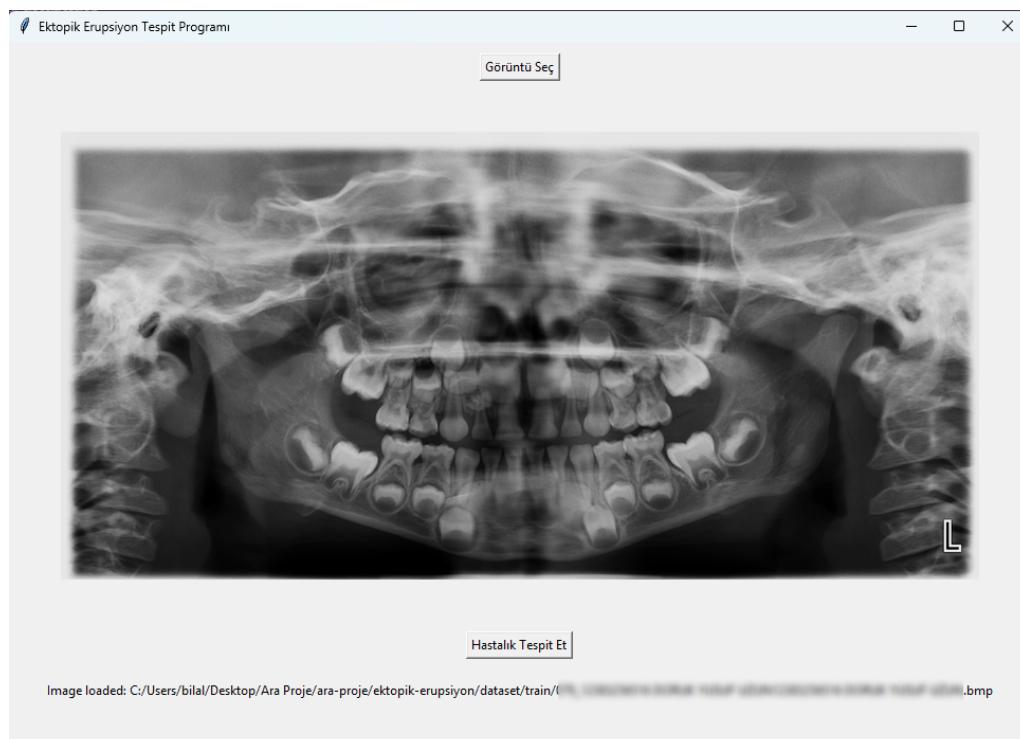
6.1 Adım Adım Uygulamanın Çalıştırılması

1. Şekil 6.1'de de görülebileceği üzere uygulama ilk çalıştırıldığında kullanıcının görüntü seçmesini sağlayan bir buton ekrana gelmektedir.



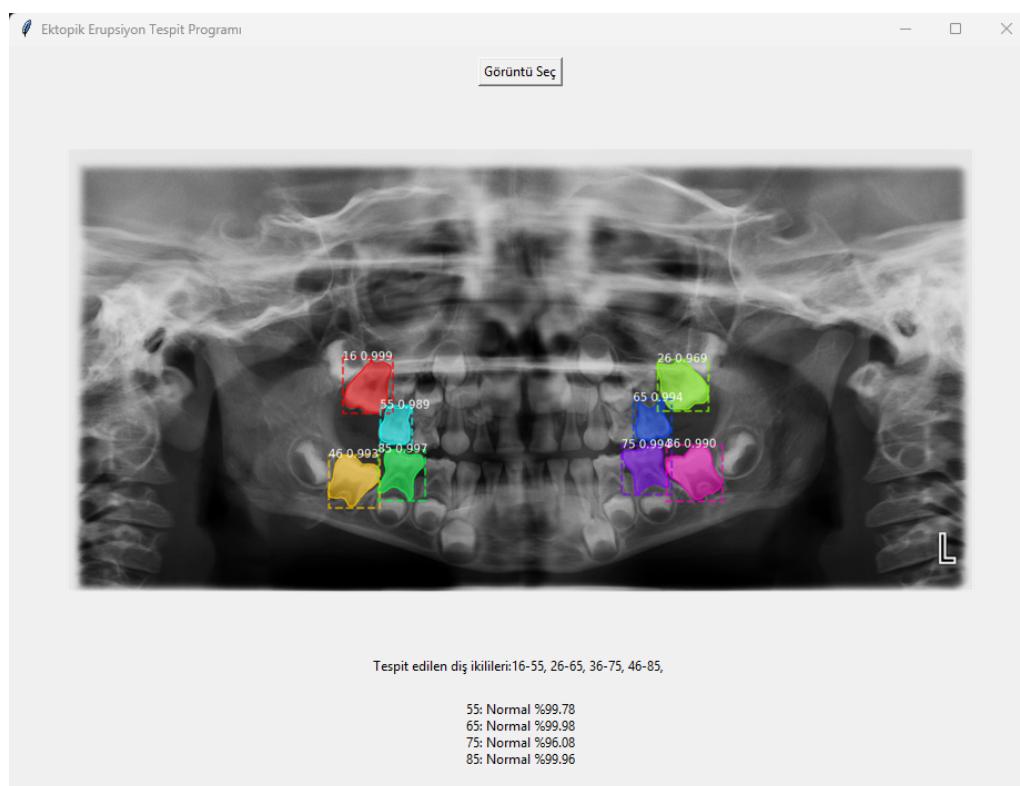
Şekil 6.1 Programın ilk çalıştırılması.

2. Şekil 6.2'de görüldüğü üzere, arayüz aracılığıyla programa röntgen görüntüsü kullanıcı tarafından yüklenir.



Şekil 6.2 Röntgen görüntüsünün programa yüklenmesi

3. Program, yüklenen bu röntgen fotoğrafını ilk önce segmentasyon modelinden geçirir. Segmentasyon modelinin sonucunda süt ve azı dişleri elde edilir. Daha sonra bu dişler kırılıarak ikili sınıflandırma modeline girdi olarak verilir. İkili sınıflandırma sonucunda dişler normal ve hastalıklı olarak sınıflandırılır. Hastalıklı olarak sınıflandırılan dişler hastalıklı diş sınıflandırma modeline verilir ve bu modelden de çıktı olarak hafif hasta, orta hasta, şiddetli hasta olmak üzere üç sınıfta bir çıktı alınır. Program sonuç olarak kullanıcıya dişin hasta olup olmadığını hasta ise de hastalığının şiddetini gösterir. Örnek çıktı Şekil 6.3'te görülmektedir.



Şekil 6.3 Görüntünün segmentasyon ve sınıflandırma sonucu

4. Program, ilgili görüntüye ait segmentasyon modelinin çıktılarını kullanıcının daha sonra da erişebilmesi adına program ile aynı dizinde bulunan output isimli klasörde saklamaktadır. Bu çıktı dosyaları grafik arayüzünde gösterilen segmente edilmiş dişlerin renkli işaretlendiği görüntüyü ve her bir diş ikilisinin kırpıldığı görüntüleri içermektedir. Output klasörüne ait örnek bir görüntü Şekil 6.4'te verilmiştir.



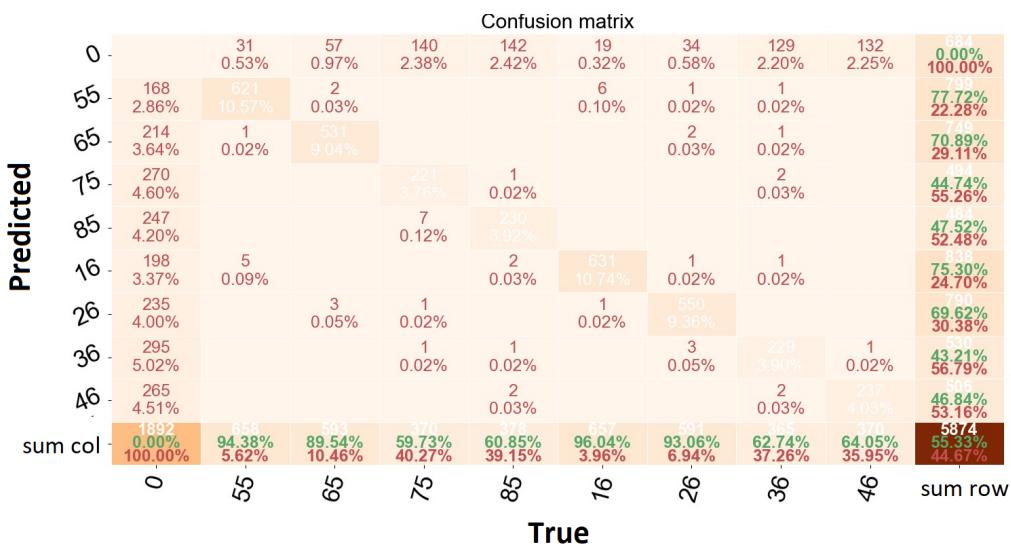
Şekil 6.4 Program Tarafından Kaydedilen Çıktı Görüntüleri

7

Deneysel Sonuçlar

7.1 Modellerin Başarısının Değerlendirilmesi

Şekil 7.1'de görülebileceği üzere model mevcut olan dişlerin tespitinde oldukça başarılı çalışmaktadır. İlgili şenlikin son sütununa bakıldığından veri kümesinde etiketlenmemiş bazı dişlerin de model tarafından bulunduğu görülmektedir. Bunun sebeplerinden biri veri kümesindeki bazı dişlerin bulunmasına rağmen etiketlenmemiş olmasıdır. Dolayısıyla son sütundaki yüzdelik değerler modelin başarısını ölçmede yanlıltıcı olabilmektedir. En alt satırdaki yüzdelik değerler en son sütundaki yüzdelik değerlere kıyasla modelin başarısı hakkında daha çok bilgi vermektedir. En alt satırda bakıldığından da üst çenede, alt çeneye kıyasla daha fazla veri olmasından dolayı modelin 16, 26, 55, 65 numaralı dişlerde; 36, 46, 75, 85 dişlerine göre daha başarılı bir sonuç verdiği gözlemlenmektedir.



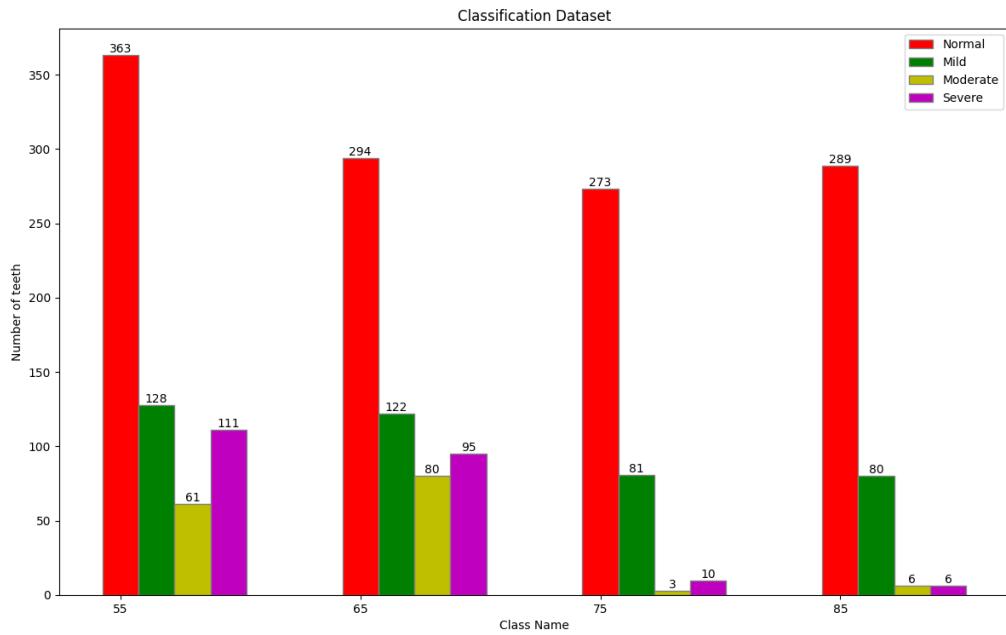
Şekil 7.1 5-Fold Segmentasyon Modelinin Hata Matrisi

Tablo 7.1'de segmentasyon ile kırılan dişleri sınıflandırmak için kullanılan sınıflandırma modellerinin başarıları gösterilmiştir. Burada DeiT ve BeiT modellerinin yaklaşık olarak benzer başarılar verdiği gözlemlenmektedir. Modeller ikili sınıflandırmada yani görüntüdeki dişin hasta mı normal mi olduğunu belirlemekte oldukça başarılı çalışmaktadır. Hastalık sınıflandırmasına geçildiği durumda ise Şekil 7.2'de de görülebileceği üzere veri kümesindeki hastalıklı dişlerin sayısının yetersizliğinden modeller pek başarılı çalışmamaktadır. 75 ve 85 numaralı dişlerde model başarılı gözükmese de bunun sebebi veri kümesinde hastalıklı olarak işaretlenen 75 ve 85 numaralı dişlerin düzgün dağılım göstermemesi ve yoğunluğunun hafif seviyede hasta olmasıdır.

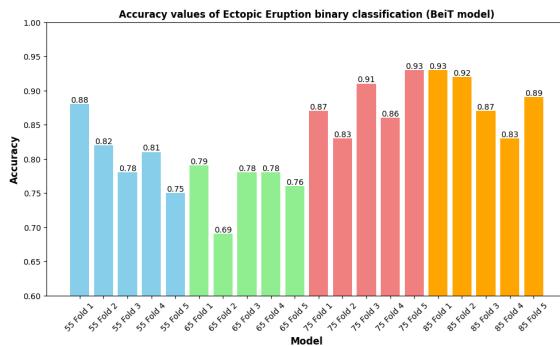
Tablo 7.1'de verilen accuracy değerlerinin renklendirilmiş grafik görüntülerini Şekil 7.3, Şekil 7.4, Şekil 7.5 ve Şekil 7.6'da gösterilmiştir.

			Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Ortalama
BeiT	İkili Sınıflandırma	55	0.88	0.82	0.78	0.81	0.75	0.81
		65	0.79	0.69	0.78	0.78	0.76	0.76
		75	0.87	0.83	0.91	0.86	0.93	0.88
		85	0.93	0.92	0.87	0.83	0.89	0.89
	Hastalık Sınıflandırması	55	0.33	0.44	0.39	0.35	0.47	0.40
		65	0.36	0.31	0.31	0.36	0.19	0.33
		75	0.88	0.88	0.94	0.94	0.94	0.92
		85	0.88	0.88	0.88	0.69	0.81	0.83
DeiT	İkili Sınıflandırma	55	0.88	0.73	0.78	0.77	0.78	0.79
		65	0.81	0.79	0.81	0.87	0.70	0.80
		75	0.72	0.75	0.91	0.84	0.87	0.82
		85	0.89	0.83	0.83	0.85	0.90	0.86
	Hastalık Sınıflandırması	55	0.42	0.35	0.39	0.32	0.35	0.37
		65	0.31	0.38	0.24	0.33	0.33	0.32
		75	0.94	0.94	0.94	0.94	0.94	0.94
		85	0.81	0.75	0.88	0.88	0.88	0.84

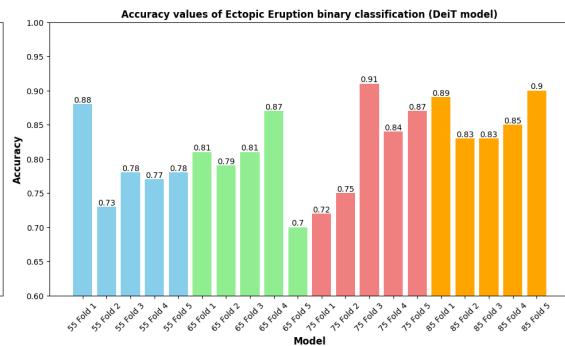
Tablo 7.1 Sınıflandırma modellerinin performans karşılaştırması



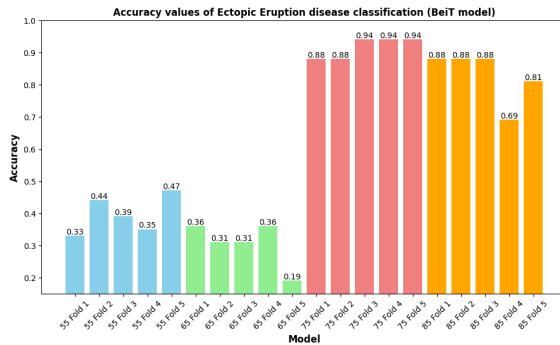
Şekil 7.2 Sınıflandırma Veri Kümesinin Dağılımı



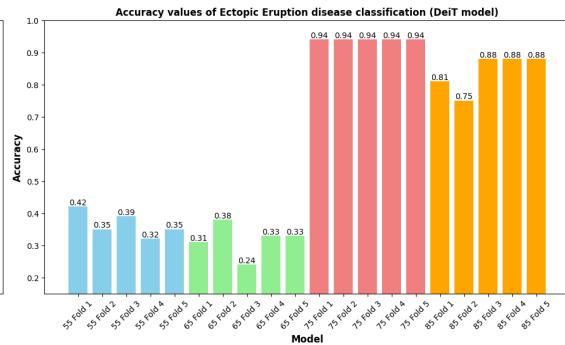
Şekil 7.3 BeiT İkili Sınıflandırma Modeli



Şekil 7.4 DeiT İkili Sınıflandırma Modeli



Şekil 7.5 BeiT Hastalıkçı Sınıflandırma Modeli

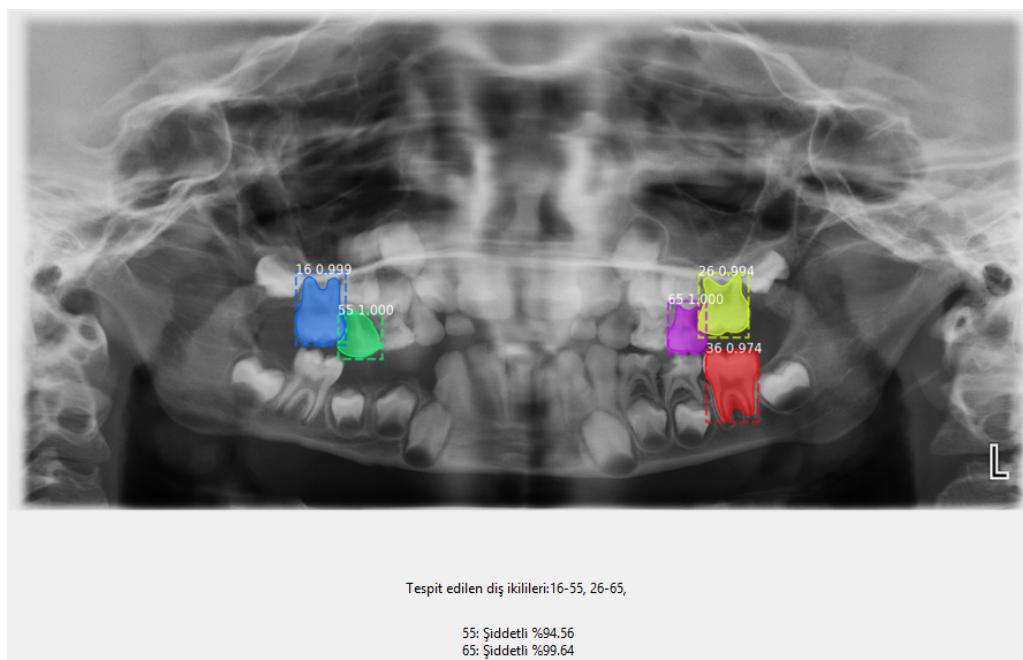


Şekil 7.6 DeiT Hastalıkçı Sınıflandırma Modeli

7.2 Uç Durumlarla Programın Test Edilmesi

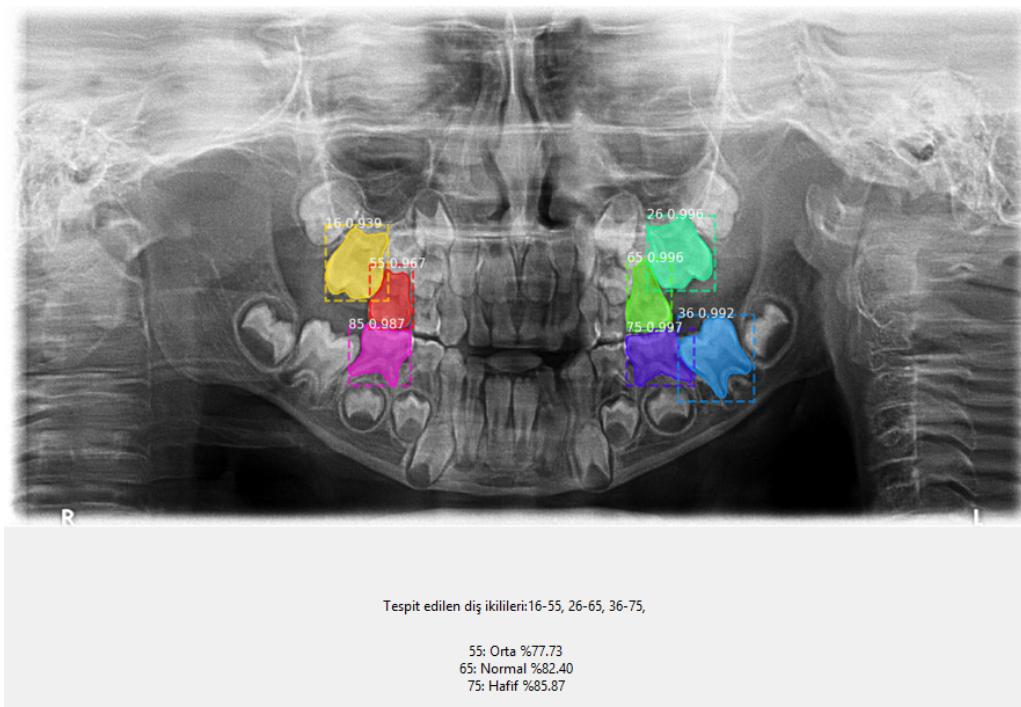
Bu çalışmada geliştirilen programın klinik ortamda aktif olarak kullanılması planlandığından programın her girdiye bir çıktı ürettiğini test etmek önemlidir.

1. Azı dişlerinde görülen ektopik erupsiyon vakaları incelenirken ilgili azı dişi ve o azı dişinin hemen yanındaki süt dişinin birbirine yaptıkları baskı durumu incelenmelidir. Dolayısıyla program ektopik erupsiyon durumunu incelerken dişleri ikili şekilde ele almaktadır. Ancak azı dişinin veya süt dişinin tek başına bulunduğu durumlarda segmentasyon modelinin bunları tespit etmesi ancak bunları sınıflandırma modeline göndermemesi gerekmektedir. Bu üç duruma ait bir çıktı Şekil 7.7'te görülmektedir. Segmentasyon modeli tarafından 36 numaralı süt dişinin tespit edilmesine rağmen 75 numaralı azı dişi tespit edilmediği için bu diş için sınıflandırma modeli çağrılmamıştır.



Şekil 7.7 Örnek Çıktı 1

2. Sınıflandırma modellerinden gelebilecek toplam 4 farklı çıktı vardır. Bunlar daha önce de bahsedildiği üzere normal, hafif hasta, orta hasta ve şiddetli hastadır. Şekil 7.8'te verilen örnekte programın normal,hafif hasta ve orta hasta olarak sınıflandırılan diş ikililerini tespit edebildiği görülmektedir.



Şekil 7.8 Örnek Çıktı 2

3. Şekil 7.9'te programın hafif hasta ve orta hasta durumlarına ek olarak şiddetli hasta durumunu da tespit edebildiği görülmektedir.



Şekil 7.9 Örnek Çıktı 3

8

Performans Analizi

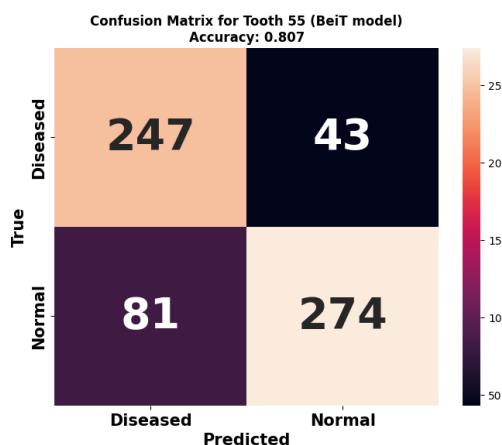
Verilen modellerin performansını değerlendirmek için modellerin accuracy, F1-skoru, precision, recall gibi metrikleri incelenebilir. Raporun "Deneysel Sonuçlar" bölümünde sınıflandırma modellerinin başarısı ortalama accuracy değerlerine bakılarak karşılaştırılmıştır ancak accuracy değeri modelleri değerlendirmede bazen yaniltıcı olabilmektedir. Bunun en temel sebebi ise veri kümelerinin dağılımının düzgün olmamasıdır. Bu bölümde ise ilgili sınıflandırma modellerinin başarısı hata matrislerine bakılarak değerlendirilecektir.

8.1 Sınıflandırma Modellerinin Hata Matrislerinin Detaylı İncelenmesi

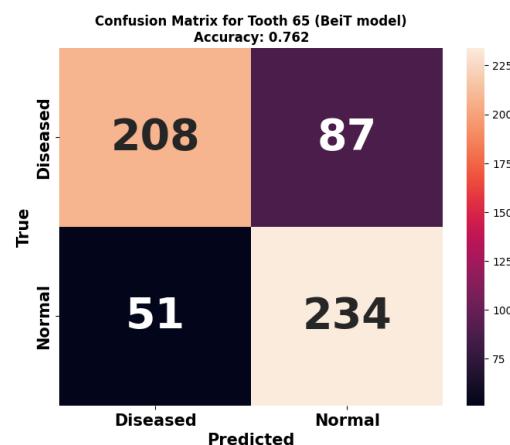
Her bir diş ikilisi için toplam 4 adet model eğitilmiştir. Bu modeller BeiT İkili Sınıflandırma, BeiT Hastalıklı Sınıflandırma, DeiT İkili Sınıflandırma ve DeiT Hastalıklı Sınıflandırma modelleridir. Toplam 4 adet diş ikilisi olduğundan toplam 16 adet hata matrisi elde edilmektedir.

8.1.1 BeiT İkili Sınıflandırma Modelinin İncelenmesi

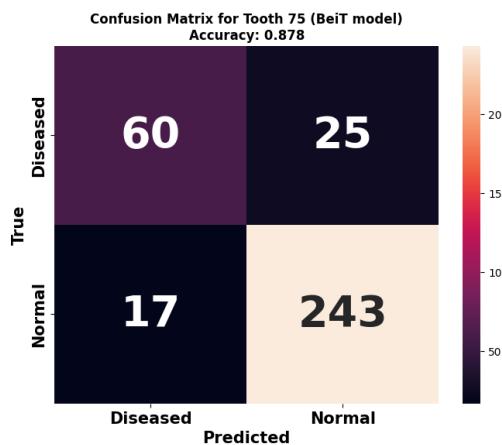
Ektopik erupsiyon vakalarının daha çok üst çenede görülmesinden dolayı veri kümemizdeki 75 ve 85 dişlerinin hastalıklı olduğu örnek sayısı azdır bu durum modelin başarısını etkilemektedir. Bu durum Şekil 8.1'deki ve Şekil 8.2'deki hata matrisleri ile Şekil 8.3'deki ve Şekil 8.4'deki hata matrisleri karşılaştırıldığında görülmektedir.



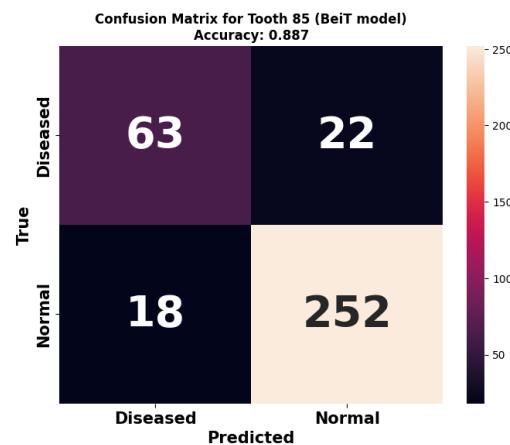
Şekil 8.1 55 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi



Şekil 8.2 65 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi



Şekil 8.3 75 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi

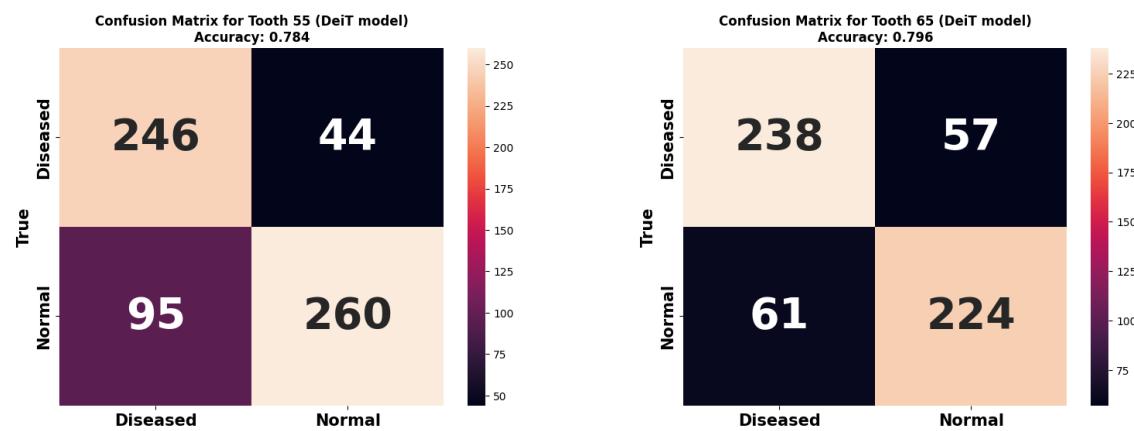


Şekil 8.4 85 Dişinin BeiT İkili Sınıflandırma Modeli Hata Matrisi

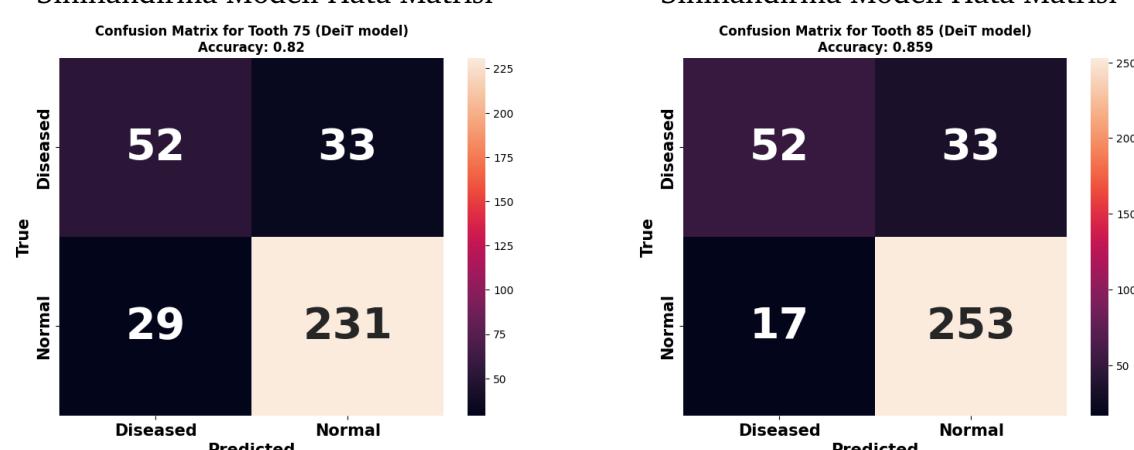
8.1.2 DeiT İkili Sınıflandırma Modelinin İncelenmesi

DeiT ve BeiT ikili sınıflandırma modelleri karşılaştırıldığında ikisinin de benzer sonuçlar verdiği görülmektedir. Bu matrisler incelendiğinde yine BeiT modelinde olduğu üzere Şekil 8.5 ve Şekil 8.6'de gösterilen üst çeneye ait dişlerin veri kümelerinin dağılımının Şekil 8.7 ve Şekil 8.8'de gösterilen alt çeneye ait dişlerin veri kümelerinin dağılımından daha düzgün olmasından dolayı üst çenede bulunan dişler için model hastalıklı örnekleri daha iyi öğrenmiştir. 55 Numaralı dişe bakıldığından hastalıklı dişlerin yaklaşık %84'ü, 65 numaralı dişte yaklaşık %80'i doğru tespit edilmiştir ancak alt çenede bu başarı düşmektedir. 75 ve 85 numaralı dişlerde hastalıklı dişlerin yaklaşık %60'ı doğru tespit edilmektedir.

Sadece accuracy değerlerine bakıldığından 75 ve 85 numaralı dişlerin modellerinin 55 ve 65 numaralı dişlerin modellerinden daha başarılı çalıştığı düşünülebilir ancak hata matrisi incelendiğinde accuracy değerleri arasındaki farkın sebebi daha iyi anlaşılmaktadır.



Şekil 8.5 55 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi



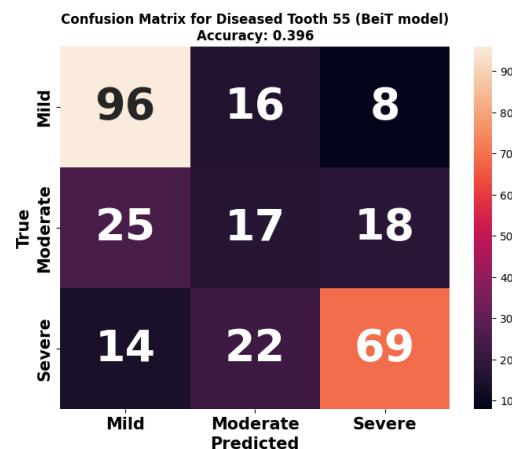
Şekil 8.7 75 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi

Şekil 8.6 65 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi

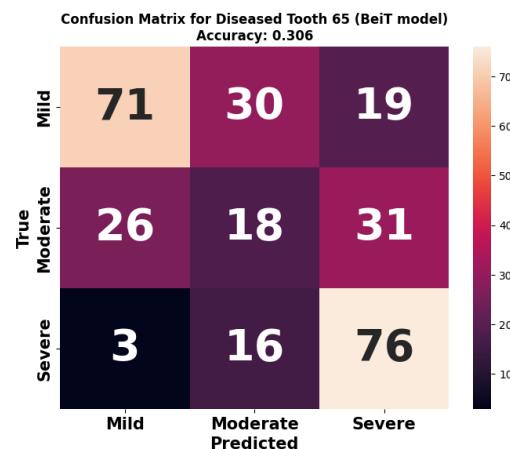
Şekil 8.8 85 Dişinin DeiT İkili Sınıflandırma Modeli Hata Matrisi

8.1.3 BeiT Hastalıklı Sınıflandırma Modelinin İncelenmesi

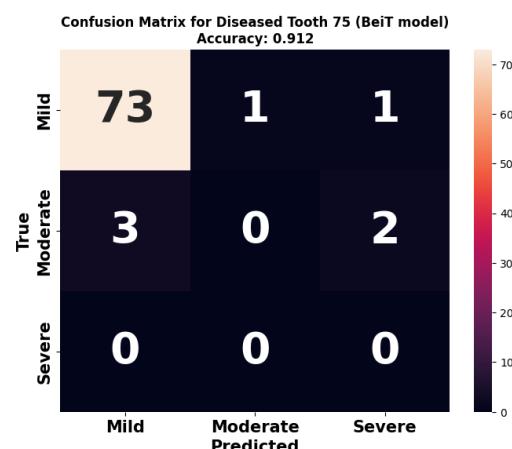
Şekil 8.9 ve Şekil 8.10 incelendiğinde modellerin üçlü sınıflandırmada ikili sınıflandırma kadar başarı elde edemediği görülmektedir. Bunun en büyük sebeplerinden biri sınıflar arası yakınlıktır. İkili sınıflandırmadaki sınıflar arasındaki fark hastalık sınlılandırımdaki sınıflar arası farktan daha nettir. Aynı zamanda hastalık sınlılandırımda geçildiğinde sadece hastalıklı dişler kullanıldığından veri kümesi de ciddi anlamda küçülmektedir. Bu durum Şekil 8.11 ve Şekil 8.12'te verilen 75 ve 85 numaralı alt çene dişleri için de geçerlidir ancak alt çenede genel olarak ektopik erupsiyon görülmemiği, görüldüğü durumlarda da hafif hasta olacak şekilde görülmesinden kaynaklı olarak buradaki veri kümesinin neredeyse tamamını hafif hasta örnekler oluşturmaktadır. Dolayısıyla buradaki modeller neredeyse tek sınıflı sınıflandırma problemi gibi çalışmaktadır bu sebeple de başarıları yüksek gözükmemektedir.



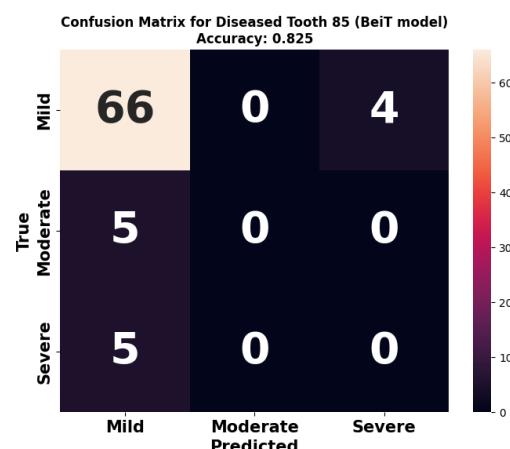
Şekil 8.9 55 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi



Şekil 8.10 65 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi



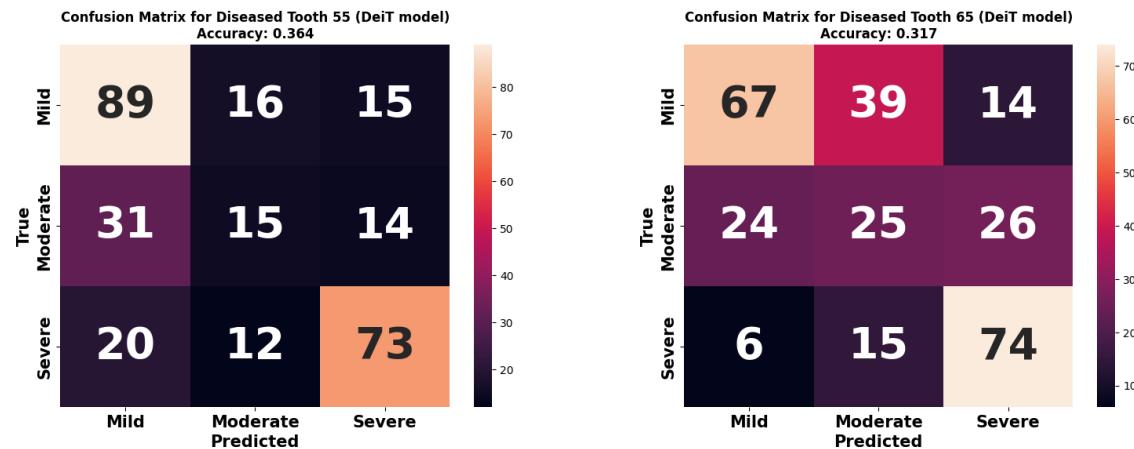
Şekil 8.11 75 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi



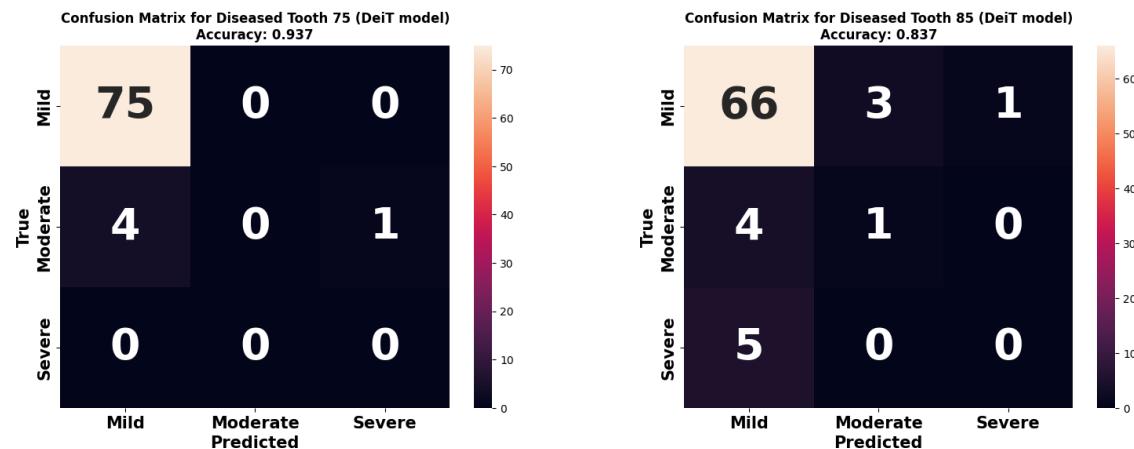
Şekil 8.12 85 Dişinin BeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi

8.1.4 DeiT Hastalıklı Sınıflandırma Modelinin İncelenmesi

Şekil 8.13, Şekil 8.14, Şekil 8.15 ve Şekil 8.16'da gözüken hata matrisleri ile BeiT Hastalıklı sınıflandırma modelinin hata matrisleri karşılaştırıldığında sonuçların hemen hemen aynı olduğu görülmektedir. Burada da 55 ve 65 numaralı dişleri sınıflar arası mesafenin küçük olması ve veri kümesinin yetersizliğinden düşük başarı göstermekte, 75 ve 85 dişleri ise veri kümesinin neredeyse tamamının tek bir sınıf olmasından dolayı yüksek başarı gösteriyor gibi gözükmemektedir.

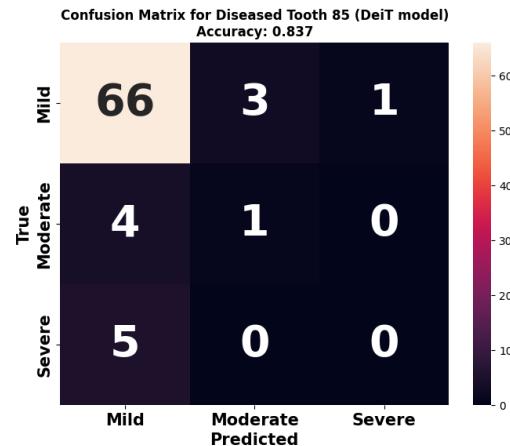


Şekil 8.13 55 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi



Şekil 8.15 75 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi

Şekil 8.14 65 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi



Şekil 8.16 85 Dişinin DeiT Hastalıklı Sınıflandırma Modeli Hata Matrisi

9 Sonuç

Sonuç olarak, yürütülen projede süt ve kalıcı azı dişlerinin radyografi görüntüsünden Mask R-CNN modeli ile tespit edilmeleri ve görüntüdeki ilgili alanın kırپılıp sınıflandırma modellerine (DeiT, BeiT) verilmesi yöntemiyle ektopik erupsiyon tespiti yüksek oranda başarılı olmuştur.

DeiT ve BeiT modellerinin karşılaştırılmasında önemli bir fark görülmemiş olup iki model de yeterince başarı göstermişlerdir. Sınıflandırma modelinin ilki olan 'Normal' - 'Hasta' olarak 2 sınıfta sınıflandırma yapan model, ikinci model olan 'Hafif' - 'Orta' - 'Şiddetli' olarak 3 sınıfta sınıflandırma yapan modele kıyasla daha yüksek bir başarı elde etmiştir. Bunun nedeni kullanılan veri kümesinin dağılımı ve büyülüğüdür. İlk modelde tüm veriler kullanılırken, ikinci modelde 'Normal' sınıfı haricindeki veriler kullanılmıştır. Bu da ikinci modelin veri kümesinin az olmasına yol açmıştır. Ayrıca üst çenedeki dişlere ait veri sayısı alt çenedeki dişlere göre daha fazla olduğu için üst çenede elde edilen başarı daha yüksektir.

Referanslar

- [1] S. Caliskan, N. Tuloglu, C. Ozdemir, S. Kizilaslan, and S. Bayrak, “Ectopic eruption of maxillary permanent first molars: Predictive factors for self-corrected and impacted outcome,” *International Journal of Clinical Practice*, vol. 75, no. 3, e13880, 2021.
- [2] I. Leandro, C. Rodrigues, S. Gómez-Martínez, and C. Umbelino, “Ectopic eruption of a lower permanent molar from the mediaeval necropolis of alcáçova do castelo, mértola, portugal,” en, *Int. J. Paleopathol.*, vol. 16, pp. 1–4, Mar. 2017.
- [3] J.-H. Yang, T.-H. Huang, Y.-Y. Wu, and C.-T. Kao, “Preservation of the ectopically-erupted maxillary lateral incisor,” *Journal of Dental Sciences*, Feb. 2024. doi: 10.1016/j.jds.2024.02.003.
- [4] J. Liu, Y. Liu, S. Li, S. Ying, L. Zheng, and Z. Zhao, “Artificial intelligence-aided detection of ectopic eruption of maxillary first molars based on panoramic radiographs,” en, *J. Dent.*, vol. 125, no. 104239, p. 104239, Oct. 2022.
- [5] H. Zhu, H. Yu, F. Zhang, Z. Cao, F. Wu, and F. Zhu, “Automatic segmentation and detection of ectopic eruption of first permanent molars on panoramic radiographs based on nnU-Net,” en, *Int. J. Paediatr. Dent.*, vol. 32, no. 6, pp. 785–792, Nov. 2022.
- [6] S. K. Ben Snyder and K. ElGalaind, *Distributed Mask RCNN training with Amazon SageMakerCV | Amazon Web Services — aws.amazon.com*, <https://aws.amazon.com/blogs/machine-learning/distributed-mask-rcnn-training-with-amazon-sagemakercv/>, [Accessed 07-06-2024], 2021.
- [7] A. Vaswani *et al.*, “Attention is all you need,” *CoRR*, vol. abs/1706.03762, 2017. arXiv: 1706 . 03762. [Online]. Available: <http://arxiv.org/abs/1706.03762>.

Özgeçmiş

BİRİNCİ ÜYE

İsim-Soyisim: Doğukan BAŞ

Doğum Tarihi ve Yeri: 05.01.2003, İstanbul

E-mail: dogukan.bas@std.yildiz.edu.tr

Telefon: 0542 894 08 11

Staj Tecrübeleri: Bosch - Application and Tool Development Engineer

İKİNCİ ÜYE

İsim-Soyisim: Bilal Müftüoğlu

Doğum Tarihi ve Yeri: 03.09.2002, İstanbul

E-mail: bilal.muftuoglu1@std.yildiz.edu.tr

Telefon: 0543 310 81 20

Staj Tecrübeleri: Kıyı Emniyeti Genel Müdürlüğü - Yazılım Departmanı«

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Python

Gerekli RAM: 8 GB

Gerekli Disk: 100 GB